תרגיל בית – מפתח/ת אוצרות התורה

תודה שהגעת לשלב הזה. התרגיל הוא דגימה קטנה של הבעיה האמיתית שאנחנו פותרים: לומד כותב שאלה בעברית של היום, והמערכת צריכה למצוא את התשובה בספר שנכתב לפני 250 שנה, מתוך סריקה.

מה בחבילה

תיקייה / קובץ	מה זה
pages/page-01.png … page-30.png	30 עמודים רצופים מתוך שו"ת נודע ביהודה, מהדורא קמא, חלק אורח חיים (דפוס ניו יורק תש"ך, צילום מדפוס ישן). המקור: HebrewBooks.org, ספר 1497, עמודי PDF 9–38.
ocr_hebrewbooks/page-NN.txt	טקסט OCR לכל עמוד, כפי שהוא קיים ב-PDF של HebrewBooks. איכות בינונית: שגיאות אותיות (למשל ה↔ש), רווחים בתוך מילים, שני טורים שלפעמים מתערבבים.
ocr_tesseract/page-NN.txt	שכבת OCR שנייה, מ-Tesseract 5 עם מודל עברית סטנדרטי. איכות נמוכה יותר, שגיאות שיטתיות.
queries.csv	12 שאילתות בעברית מודרנית.

הטקסט המודפס הוא עברית רבנית של המאה ה-18, עם ראשי תיבות רבים (מע"ל, א"כ, ס"ק, וכו'), ציטוטים מהגמרא בארמית, והפניות למקורות ("סי' קכ"ח במג"א ס"ק מ"ה"). כל תשובה (סימן) מתחילה בשאלה או בפנייה לשואל, ולעיתים כמה סימנים נמצאים באותו עמוד.

המשימה

לבנות כלי שמקבל שאילתה מ-queries.csv ומחזיר את **העמוד והפסקה** שבהם נמצאת התשובה לשאלה, לפי הסדר הטוב ביותר שתוכל. לכל שאילתה החזר עד 3 מועמדים (עמוד + ציטוט קצר של תחילת הפסקה או תיאור מיקומה).
הפלט הוא מיקום, לא תשובה. אל תנסח סיכום הלכתי או "תשובה" משלך: הלומד צריך לראות את הדף המקורי במקום הנכון. אם השתמשת במודל שפה, תפקידו הוא לעזור למצוא ולאמת, לא לענות.
חלק מהשאילתות אין להן תשובה בחומר. הכלי צריך לדעת להגיד את זה, ולא להחזיר "משהו".

מה להגיש (חובה)

1. **הקוד**, בכל שפה וכלים שתבחר, בריפו GitHub **פרטי** עם הרשאת צפייה למשתמש nirkon@gmail.com. מותר להשתמש בספריות, במודלים, בשירותי ענן, ב-OCR אחר, בכל דבר. אם השתמשת במודל שפה גדול, ציין איזה ובאיזה אופן.
2. **אריזה**docker-compose : שעולה בפקודה אחת (docker compose up) ורץ מקומית לפי README קצר. הכלי צריך לכלול ממשק מינימלי (שורת פקודה או דף web פשוט) שמקבל שאילתה ומציג את המועמדים.
3. **results.csv**: שורה לכל שאילתה: id, rank, page, snippet_or_location, confidence. ל"אין תשובה" שורה אחת עם page ריק ו-snippet "לא נמצא".

4. **דף אחד** (עד עמוד 4A, טקסט חופשי) שעונה על ארבע שאלות: מה בחרת לעשות ולמה, כולל מה החלטת *לא* לעשות; איפה הכלי שלך נכשל ולמה לדעתך; מה היית עושה עם עוד שבוע; מה היית שואל את הצוות התורני לפני שממשיכים.

מפתחות למודלי שפה

אין צורך במודל שפה כדי לעמוד בתרגיל: שיטה קלאסית או מודל מקומי (Ollama, Hugging Face) הם לגיטימיים לחלוטין ולא נקודה לרעה. אם בחרת להשתמש בשירות בתשלום, קרא מפתחות ממשתני סביבה ותאר ב-README איך להזין מפתח שלנו (קובץ .env.example בלי מפתחות אמיתיים). אל תעלה מפתחות לריפו, ואל תשלח לנו מפתחות אישיים. כל מועמד יקבל במייל מפתח DeepInfra אישי עם תקציב של 7 דולר לתרגיל. אפשר להשתמש בו בכל מודל מהקטלוג של DeepInfra (מודלי embedding, מודלי שפה ועוד), לבחירתך, דרך API תואם OpenAI. אם התקציב לא מספיק, כתוב לנו ונגדיל אותו:

```
base_url = https://api.deepinfra.com/v1/openai
```

השוואה בין מודלי embedding על עברית וארמית רבנית יש בטבלה של ספריא:
`https://huggingface.co/datasets/Sefaria/Rabbinic-Embedding-Leaderboard`

בונוס (לא חובה)

הסטאק שלנו הוא Python/FastAPI בצד השרת, React/TypeScript בצד הממשק. מי שעובד בו, ומוסיף בדיקות אוטומטיות ו-lint, מקבל נקודות זכות. זה יתרון, לא דרישה: כלי טוב ב-stack אחר עדיף על כלי חלש ב-stack שלנו.

מסגרת

- עד 8 שעות עבודה, עד שבוע קלנדרי מקבלת החבילה. אם לא הספקת, תגיש מה שיש עם הסבר. העדפה ברורה לכלי חלקי שמוסבר היטב על פני כלי "מלא" בלי ניתוח.
- אין תשובה "נכונה" אחת. מה שמעניין אותנו הוא אופן החשיבה: איך התמודדת עם ה-OCR, איך גישרת בין לשון השאלה ללשון הספר, ואיך אתה יודע מתי לא מצאת.
- אפשר לשאול שאלות הבהרה במייל לפני שמתחילים.

בהצלחה.